

Estimation statistique - Calcul différentiel

La difficulté des exercices est indiquée par le nombre d'étoile(s) : applicatif (★), classique (★★) et exploratoire (★★★).

Cette indication n'a rien d'absolu : ne vous découragez pas pour quelques petites étoiles !

Pour toute question ou remarque, n'hésitez pas à m'écrire à l'adresse mhacini.pro@gmail.com

Modern statisticians are familiar with the notion that any finite body of data contains only a limited amount of information on any point under examination; that this limit is set by the nature of the data themselves, and cannot be increased by any amount of ingenuity expended in their statistical examination: that the statistician's task, in fact, is limited to the extraction of the whole of the available information on any particular issue.

– R.A Fisher

Le lion est mort ce soir (★★)

On cherche à évaluer le nombre N de lions d'Asie, espèce en voie de disparition, encore en vie dans la forêt de Gir. Pour cela, on capture d'abord en une seule fois m lions ($m \in \mathbb{N}^*$), que l'on tatoue avant de les relâcher dans la nature. On admet que, pendant toute la durée de l'étude, il n'y a ni naissance ni décès, puis l'on utilise l'une des deux méthodes suivantes.

1. Première méthode.

On capture successivement au hasard (donc avec équiprobabilité), et avec remise en liberté après observation du sujet, n lions. On note Y_n le nombre de lions tatoués parmi eux.

- Déterminer la loi de Y_n . En déduire que $\frac{Y_n}{mn}$ est un estimateur sans biais et convergent de $\frac{1}{N}$.
- Pourquoi ne peut-on pas prendre $m \frac{n}{Y_n}$ comme estimateur de N ?
- On pose $B_n = \frac{m(n+1)}{Y_{n+1}}$. Calculer l'espérance de B_n , et montrer que B_n est un estimateur asymptotiquement sans biais de N .

2. Deuxième méthode.

On se donne $n \in \mathbb{N}^*$. On capture également, un par un, et avec remise en liberté après observation du sujet, des lions de Gir jusqu'à en obtenir n tatoués. On note X_n la variable aléatoire égale au nombre de lions qu'il a été nécessaire de capturer pour en obtenir n tatoués. On pose $D_1 = X_1$, et pour tout $i \in \llbracket 2, n \rrbracket$, $D_i = X_i - X_{i-1}$. On admet que les D_i sont mutuellement indépendantes.

- Pour tout $i \in \llbracket 2, n \rrbracket$, que représente concrètement D_i ?
- Déterminer, pour tout $i \in \llbracket 2, n \rrbracket$, la loi de D_i , son espérance et sa variance. En déduire l'espérance et la variance de X_n .
- On pose $A_n = \frac{m}{n} X_n$. Montrer que A_n est un estimateur sans biais et convergent de N , et déterminer son risque quadratique.

Maximum de vraisemblance (★★)

Pour $a > 0$, on note

$$f_a(t) = \begin{cases} 0 & \text{si } t < 1 \\ \frac{a}{t^{a+1}} & \text{si } t \geq 1. \end{cases}$$

On considère alors une suite $(X_n)_{n \in \mathbb{N}^*}$ de variables aléatoires i.i.d. de densité f_a , où a est inconnu. Pour $n \in \mathbb{N}^*$, on définit une fonction L_n (appelée fonction de vraisemblance) par

$$L_n : ([1, +\infty[)^n \times \mathbb{R}_+^* \rightarrow \mathbb{R}_+, \\ (x_1, \dots, x_n, a) \mapsto \prod_{i=1}^n f_a(x_i).$$

1. Pour $(x_1, \dots, x_n)$ fixés, montrer que $a \mapsto L_n(x_1, \dots, x_n, a)$ possède un maximum atteint en un unique réel a que l'on exprimera en fonction de $x_1, \dots, x_n$. On pourra à cet effet étudier les variations de la fonction $a \mapsto \ln(L_n(x_1, \dots, x_n, a))$.

On a donc trouvé une expression de $a = \varphi_n(x_1, \dots, x_n)$ où φ_n est une fonction définie sur $([1, +\infty[)^n$. On pose alors $T_n = \varphi_n(X_1, \dots, X_n)$, et on appelle T_n estimateur du maximum de vraisemblance.

2. Montrer que pour $k \in \llbracket 1, n \rrbracket$, $\ln(X_k)$ suit une loi exponentielle dont on précisera le paramètre. En déduire une densité de $S_n = \ln(X_1) + \dots + \ln(X_n)$.
3. Exprimer T_n en fonction de S_n . En déduire $E(T_n)$ et $V(T_n)$.
4. Montrer que T_n est un estimateur asymptotiquement sans biais et convergent de a .

Brutal (★★★)

Soient $n \geq 1$ et $(X_1, \dots, X_n)$ un échantillon identiquement distribué indépendant de loi de Poisson de paramètre $\lambda > 0$ inconnu. On pose

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{et} \quad T_n = \sqrt{n} \frac{\bar{X}_n - \lambda}{\sqrt{\lambda}}.$$

En utilisant T_n , déterminer un intervalle de confiance asymptotique de λ au niveau de risque α .

Optimisation Convexe (★★)

Soit $n \in \mathbb{N}$ tel que $n \geq 2$. L'espace vectoriel $\mathbb{R}^n$ est muni de sa structure euclidienne canonique, le produit scalaire étant noté $\langle \cdot, \cdot \rangle$ et la norme associée $\|\cdot\|$. Soit f une application de classe C^1 définie sur $\mathbb{R}^n$, à valeurs dans $\mathbb{R}$, convexe, c'est-à-dire vérifiant pour tout $(x, y) \in (\mathbb{R}^n)^2$ et pour tout réel $\lambda \in [0, 1]$:

$$f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y).$$

Pour tout $(h, x) \in (\mathbb{R}^n)^2$ fixé, on définit la fonction $\varphi_{h,x}$ de la variable réelle t par :

$$\varphi_{h,x}(t) = f(x + th).$$

1. a. Montrer que $\varphi_{h,x}$ est une fonction convexe de $\mathbb{R}$ dans $\mathbb{R}$.
b. En déduire que $\varphi_{h,x}'(0) \leq \varphi_{h,x}(1) - \varphi_{h,x}(0)$.
2. Montrer que pour tout $(x, y) \in (\mathbb{R}^n)^2$, on a

$$\langle \nabla f(x), y - x \rangle \leq f(y) - f(x).$$

En déduire que si x est un point critique de f , alors f possède un minimum, atteint en x .

3. On suppose dans cette question que $f(0) = 0$ et que $\nabla f(0) = 0$. On suppose également que f est strictement convexe, c'est-à-dire qu'elle vérifie pour tout $(x, y) \in (\mathbb{R}^n)^2$, tels que $x \neq y$, pour tout réel $\lambda \in]0, 1[$:

$$f((1 - \lambda)x + \lambda y) < (1 - \lambda)f(x) + \lambda f(y).$$

- a. Montrer que pour tout $x \in \mathbb{R}^n$, $f(0) \leq f(x)$, puis que si $x \neq 0$, alors $f(x) > 0$.
- b. Montrer que $\inf_{x \in \mathbb{R}^n, \|x\|=1} f(x)$ existe. On note α cette valeur. Montrer que $\alpha > 0$.
- c. Montrer que pour tout $\|x\| > 1$, $|f(x)| \geq \alpha\|x\|$. En déduire la valeur de $\lim_{\|x\| \rightarrow +\infty} f(x)$.