Estimation statistique - Calcul différentiel

La difficulté des exercices est inquée par le nombre d'étoile(s) : applicatif (★), classique (★ ★) et exploratoire (★ ★ ★).
Cette indication n'a rien d'absolu : ne vous découragez pas pour quelques petites étoiles !
Pour toute question ou remarque, n'hésitez pas à m'écrire à l'adresse mhacini.pro@gmail.com

Il faut donc que l'élève se mette en état, d'une part, de pouvoir écrire en analyse tous les mouvements qu'il peut concevoir dans l'espace, et, de l'autre, de se représenter perpétuellement dans l'espace le spectacle mouvant dont chacune des opérations analytiques est l'écriture.

Gaspard Monge - *Cours de Géométrie descriptive* (1746 - 1818)

Le lion est mort ce soir (★★)

On cherche à évaluer le nombre N de lions d'Asie, espèce en voie de disparition, encore en vie dans la forêt de Gir. Pour cela, on capture d'abord en une seule fois m lions ($m \in \mathbb{N}^*$), que l'on tatoue avant de les relâcher dans la nature. On admet que, pendant toute la durée de l'étude, il n'y a ni naissance ni décès, puis l'on utilise l'une des deux méthodes suivantes.

1. Première méthode. On capture successivement au hasard (donc avec équiprobabilité), et avec remise en liberté après observation du sujet, n lions. On note Y_n le nombre de lions tatoués parmi eux.
   a. Déterminer la loi de Y_n. En déduire que $\frac{Y_n}{mn}$ est un estimateur sans biais et convergent de $\frac{1}{N}$.
   b. Pourquoi ne peut-on pas prendre $m\frac{n}{Y_n}$ comme estimateur de N ?
   c. On pose $B_n = \frac{m(n+1)}{Y_n+1}$. Calculer l'espérance de B_n, et montrer que B_n est un estimateur asymptotiquement sans biais de N.
2. Deuxième méthode. On se donne $n \in \mathbb{N}^*$. On capture également, un par un, et avec remise en liberté après observation du sujet, des lions de Gir jusqu'à en obtenir n tatoués. On note X_n la variable aléatoire égale au nombre de lions qu'il a été nécessaire de capturer pour en obtenir n tatoués. On pose $D_1 = X_1$, et pour tout $i \in [\![2, n]\!]$, $D_i = X_i - X_{i-1}$. On admet que les D_i sont mutuellement indépendantes.
   a. Pour tout $i \in [\![2, n]\!]$, que représente concrètement D_i ?
   b. Déterminer, pour tout $i \in [\![2, n]\!]$, la loi de D_i, son espérance et sa variance. En déduire l'espérance et la variance de X_n.
   c. On pose $A_n = \frac{m}{n}X_n$. Montrer que A_n est un estimateur sans biais et convergent de N, et déterminer son risque quadratique.

Correction :

1. Première méthode.
   a. Pour tout $i \in [\![1, n]\!]$, notons Z_i la variable indicatrice de l'événement « le i-ième lion capturé est tatoué ». À chaque capture, la probabilité d'obtenir un lion tatoué vaut $\frac{m}{N}$,

donc Z_i suit une loi de Bernoulli $\mathcal{B}\left(\frac{m}{N}\right)$. De plus, les captures étant faites avec remise, les Z_i sont indépendantes.

Ainsi,

$$Y_n = \sum_{i=1}^{n} Z_i,$$

donc Y_n suit une loi binomiale $\mathcal{B}\left(n, \frac{m}{N}\right)$.

En particulier,

$$E(Y_n) = n\frac{m}{N},$$

d'où

$$E\left(\frac{Y_n}{mn}\right) = \frac{1}{N}.$$

Donc $\frac{Y_n}{mn}$ est un estimateur sans biais de $\frac{1}{N}$.

De plus, comme $Y_n = \sum_{i=1}^{n} Z_i$ avec les Z_i i.i.d., la loi faible des grands nombres donne

$$\frac{Y_n}{n} \underset{n\to+\infty}{\to} \frac{m}{N}$$

en probabilité. En multipliant par $\frac{1}{m}$, on obtient

$$\frac{Y_n}{mn} \underset{n\to+\infty}{\to} \frac{1}{N},$$

donc $\frac{Y_n}{mn}$ est aussi un estimateur convergent de $\frac{1}{N}$.

b. Le fait que $\frac{Y_n}{mn}$ soit sans biais pour $\frac{1}{N}$ n'implique pas que son inverse soit sans biais pour N. Plus concrètement, si $m < N$, on a

$$P(Y_n = 0) = \left(1 - \frac{m}{N}\right)^n > 0,$$

de sorte que $m\frac{n}{Y_n}$ n'est même pas toujours défini.

c. Par le théorème de transfert,

$$\begin{aligned}
E(B_n) &= \sum_{k=0}^{n} \frac{m(n+1)}{k+1} P(Y_n = k) \\
&= \sum_{k=0}^{n} \frac{m(n+1)}{k+1} \binom{n}{k} \left(\frac{m}{N}\right)^k \left(1 - \frac{m}{N}\right)^{n-k} \\
&= \sum_{k=0}^{n} m \binom{n+1}{k+1} \left(\frac{m}{N}\right)^k \left(1 - \frac{m}{N}\right)^{n-k} \\
&= N \sum_{j=1}^{n+1} \binom{n+1}{j} \left(\frac{m}{N}\right)^j \left(1 - \frac{m}{N}\right)^{(n+1)-j} \\
&= N\left(1 - \left(1 - \frac{m}{N}\right)^{n+1}\right).
\end{aligned}$$

Donc le biais de B_n vaut

$$E(B_n) - N = -N\left(1 - \frac{m}{N}\right)^{n+1} \underset{n \to +\infty}{\to} 0.$$

Ainsi, B_n est un estimateur asymptotiquement sans biais de N.

2. Deuxième méthode.

   a. Pour tout $i \in [\![2, n]\!]$, D_i représente le nombre de lions capturés entre la capture du $(i-1)$-ième lion tatoué (exclue) et celle du i-ième lion tatoué (incluse).

   b. À chaque capture, la probabilité d'obtenir un lion tatoué vaut $\frac{m}{N}$. Ainsi, pour tout $i \in [\![1, n]\!]$, D_i suit une loi géométrique de paramètre $\frac{m}{N}$. Donc

$$E(D_i) = \frac{N}{m} \quad \text{et} \quad V(D_i) = \frac{1 - \frac{m}{N}}{\left(\frac{m}{N}\right)^2} = \frac{N(N-m)}{m^2}.$$

   Or

$$X_n = \sum_{i=1}^{n} D_i.$$

   Par linéarité de l'espérance et indépendance des D_i,

$$E(X_n) = n\frac{N}{m} \quad \text{et} \quad V(X_n) = n\frac{N(N-m)}{m^2}.$$

   c. On a

$$E(A_n) = \frac{m}{n} E(X_n) = N,$$

   donc A_n est sans biais.

   De plus,

$$A_n = m\left(\frac{1}{n}\sum_{i=1}^{n} D_i\right).$$

La loi faible des grands nombres donne

$$\frac{1}{n}\sum_{i=1}^{n} D_i \underset{n\to+\infty}{\to} \frac{N}{m}$$

en probabilité. On en déduit

$$A_n \underset{n\to+\infty}{\to} N$$

en probabilité, donc A_n est convergent.

Enfin, son risque quadratique vaut

$$E\left((A_n - N)^2\right) = V(A_n) = \left(\frac{m}{n}\right)^2 V(X_n) = \frac{N(N-m)}{n}.$$

Maximum de vraisemblance (★★)

Pour $a > 0$, on note

$$f_a(t) = \begin{cases} 0 & \text{si } t < 1 \\ \frac{a}{t^{a+1}} & \text{si } t \geq 1 \end{cases}.$$

On considère alors une suite $(X_n)_{n\in\mathbb{N}^*}$ de variables aléatoires i.i.d. de densité f_a, où a est inconnu. Pour $n \in \mathbb{N}^*$, on définit une fonction L_n (appelée fonction de vraisemblance) par

$$L_n : ([1, +\infty[)^n \times \mathbb{R}_+^* \to \mathbb{R}_+, \quad (x_1, \dots, x_n, a) \mapsto \prod_{i=1}^{n} f_a(x_i).$$

1. Pour $(x_1, \dots, x_n)$ fixés, montrer que $a \mapsto L_n(x_1, \dots, x_n, a)$ possède un maximum atteint en un unique réel a que l'on exprimera en fonction de $x_1, \dots, x_n$. On pourra à cet effet étudier les variations de la fonction $a \mapsto \ln(L_n(x_1, \dots, x_n, a))$.

   On a donc trouvé une expression de $a = \varphi_{n(x_1,\dots,x_n)}$ où φ_n est une fonction définie sur $([1, +\infty[)^n$. On pose alors $T_n = \varphi_{n(X_1,\dots,X_n)}$, et on appelle T_n estimateur du maximum de vraisemblance.
2. Montrer que pour $k \in [\![1, n]\!]$, $\ln(X_k)$ suit une loi exponentielle dont on précisera le paramètre. En déduire une densité de $S_n = \ln(X_1) + \dots + \ln(X_n)$.
3. Exprimer T_n en fonction de S_n. En déduire $E(T_n)$ et $V(T_n)$.
4. Montrer que T_n est un estimateur asymptotiquement sans biais et convergent de a.

Correction :

1. On a

$$L_n(x_1, \dots, x_n, a) = a^n \prod_{i=1}^{n} \frac{1}{x_i^{a+1}},$$

de sorte que

$$\ln(L_n(x_1, \dots, x_n, a)) = n \ln(a) - (a+1) \sum_{i=1}^{n} \ln(x_i).$$

En particulier, la fonction $a \mapsto \ln(L_n(x_1, \dots, x_n, a))$ est dérivable, de dérivée

$$\frac{n}{a} - \sum_{i=1}^{n} \ln(x_i).$$

Cette dérivée est positive si et seulement si

$$a \leq \frac{n}{\sum_{i=1}^{n} \ln(x_i)}.$$

Donc la fonction $a \mapsto \ln(L_n(x_1, \dots, x_n, a))$ admet un maximum en

$$a = \frac{n}{\sum_{i=1}^{n} \ln(x_i)}.$$

Par croissance de la fonction exponentielle, il en est de même de la fonction $a \mapsto L_n(x_1, \dots, x_n, a)$.

Dans la suite, on pose donc

$$T_n = \frac{n}{\sum_{i=1}^{n} \ln(X_i)}.$$

2. Puisque X_k ne prend que des valeurs supérieures à 1, $\ln(X_k)$ ne prend que des valeurs positives, de sorte que

$$P(\ln(X_k) \leq x) = 0$$

si $x < 0$. Si $x \geq 0$, alors

$$P(\ln(X_k) \leq x) = P(X_k \leq e^x) = \int_1^{e^x} \frac{a}{t^{a+1}} \, \mathrm{d}t = \left[-\frac{1}{t^a} \right]_1^{e^x} = 1 - e^{-ax}.$$

Donc $\ln(X_k)$ suit une loi exponentielle de paramètre a.

On en déduit que $a \ln(X_k)$ suit une loi exponentielle de paramètre 1, et donc que aS_n admet pour densité

$$g_{n(t)} = \begin{cases} 0 & \text{si } t \leq 0 \\ \frac{1}{(n-1)!} t^{n-1} e^{-t} & \text{si } t > 0 \end{cases}.$$

Par transformation affine des densités, une densité de S_n est alors

$$t \mapsto ag_{n(at)} = \begin{cases} 0 & \text{si } t \leq 0 \\ \frac{a^n}{(n-1)!} t^{n-1} e^{-at} & \text{si } t > 0 \end{cases}.$$

3. On a $T_n = \frac{n}{S_n}$. Donc, par le théorème de transfert, sous réserve de convergence,

$$\begin{aligned} E(T_n) &= \int_0^{+\infty} \frac{n}{t}\left(\frac{a^n}{(n-1)!}\right) t^{n-1} e^{-at} \, \mathrm{d}t \\ &= n \frac{a^2}{(n-1)!} \int_0^{+\infty} (at)^{n-2} e^{-at} \, \mathrm{d}t. \end{aligned}$$

Un changement de variable $x = at$ donne alors

$$\begin{aligned} E(T_n) &= n \frac{a^2}{(n-1)!} \int_0^{+\infty} x^{n-2} e^{-x} \, \mathrm{d}\frac{x}{a} \\ &= a \frac{n}{(n-1)!}(n-2)! = a \frac{n}{n-1}. \end{aligned}$$

De même, toujours sous réserve de convergence,

$$\begin{aligned} E\left(T_n^2\right) &= \int_0^{+\infty} \frac{n^2}{t^2}\left(\frac{a^n}{(n-1)!}\right) t^{n-1} e^{-at} \, \mathrm{d}t \\ &= n^2 \frac{a^3}{(n-1)!} \int_0^{+\infty} (at)^{n-3} e^{-at} \, \mathrm{d}t. \end{aligned}$$

Le même changement de variable donne

$$\begin{aligned} E\left(T_n^2\right) &= n^2 \frac{a^3}{(n-1)!} \int_0^{+\infty} x^{n-3} e^{-x} \, \mathrm{d}\frac{x}{a} \\ &= n^2 \frac{a^2}{(n-1)!}(n-3)! = n^2 \frac{a^2}{(n-1)(n-2)}. \end{aligned}$$

La formule de Huygens donne alors

$$V(T_n) = E\left(T_n^2\right) - E(T_n)^2 = n^2 \frac{a^2}{(n-1)(n-2)} - n^2 \frac{a^2}{(n-1)^2} = n^2 \frac{a^2}{(n-1)^2(n-2)}.$$

4. On a déjà

$$b(T_n) = E(T_n) - a = \frac{a}{n-1} \underset{n \to +\infty}{\to} 0,$$

donc T_n est un estimateur asymptotiquement sans biais de a.

Et le risque quadratique de T_n en a vaut

$$r(T_n) = b(T_n)^2 + V(T_n) = \frac{a^2}{(n-1)^2} + n^2 \frac{a^2}{(n-1)^2(n-2)} = a^2 \frac{n^2+n-2}{(n-1)^2(n-2)} \underset{n \to +\infty}{\to} 0.$$

Puisque le risque quadratique tend vers 0, on en déduit que T_n est un estimateur convergent de a.

Brutal (★★★)

Soient $n \geq 1$ et $(X_1, \ldots, X_n)$ un échantillon identiquement distribué indépendant de loi de Poisson de paramètre $\lambda > 0$ inconnu. On pose

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{et} \quad T_n = \sqrt{n}\frac{\bar{X}_n - \lambda}{\sqrt{\lambda}}.$$

En utilisant T_n, déterminer un intervalle de confiance asymptotique de λ au niveau de risque α.

Correction :
Par le théorème central limite, T_n converge en loi vers une variable aléatoire X suivant la loi normale centrée réduite. Donc, pour tous réels $a < b$,

$$\lim_{n\to+\infty} P(a \leq T_n \leq b) = P(a \leq X \leq b) = \Phi(b) - \Phi(a).$$

En particulier, soit t_α l'unique réel tel que $\Phi(t_\alpha) = 1 - \frac{\alpha}{2}$. Alors

$$\lim_{n\to+\infty} P\left(-t_\alpha \leq \sqrt{n}\frac{\bar{X}_n - \lambda}{\sqrt{\lambda}} \leq t_\alpha\right) = 1 - \alpha.$$

Soit encore

$$\lim_{n\to+\infty} P\left(\lambda - \frac{t_\alpha}{\sqrt{n}}\sqrt{\lambda} \leq \bar{X}_n \leq \lambda + \frac{t_\alpha}{\sqrt{n}}\sqrt{\lambda}\right) = 1 - \alpha.$$

Mais

$$\lambda - \frac{t_\alpha}{\sqrt{n}}\sqrt{\lambda} = \left(\sqrt{\lambda} - \frac{t_\alpha}{2\sqrt{n}}\right)^2 - \frac{t_\alpha^2}{4n}$$

et de même

$$\lambda + \frac{t_\alpha}{\sqrt{n}}\sqrt{\lambda} = \left(\sqrt{\lambda} + \frac{t_\alpha}{2\sqrt{n}}\right)^2 - \frac{t_\alpha^2}{4n}.$$

Donc

$$\lim_{n\to+\infty} P\left(\left(\sqrt{\lambda} - \frac{t_\alpha}{2\sqrt{n}}\right)^2 - \frac{t_\alpha^2}{4n} \leq \bar{X}_n \leq \left(\sqrt{\lambda} + \frac{t_\alpha}{2\sqrt{n}}\right)^2 - \frac{t_\alpha^2}{4n}\right) = 1 - \alpha.$$

Pour n suffisamment grand, on a $\sqrt{\lambda} - \frac{t_\alpha}{2\sqrt{n}} \geq 0$, et l'événement précédent équivaut à

$$\left[\left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} - \frac{t_\alpha}{2\sqrt{n}}\right)^2 \leq \lambda \leq \left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} + \frac{t_\alpha}{2\sqrt{n}}\right)^2\right].$$

On en déduit que

$$\lim_{n\to+\infty} P\left(\left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} - \frac{t_\alpha}{2\sqrt{n}}\right)^2 \leq \lambda \leq \left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} + \frac{t_\alpha}{2\sqrt{n}}\right)^2\right) = 1 - \alpha.$$

Ainsi, un intervalle de confiance asymptotique de λ au niveau de confiance $1-\alpha$ est

$$\left[\left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} - \frac{t_\alpha}{2\sqrt{n}}\right)^2, \left(\sqrt{\bar{X}_n + \frac{t_\alpha^2}{4n}} + \frac{t_\alpha}{2\sqrt{n}}\right)^2\right].$$

Optimisation Convexe (★★)

Soit $n \in \mathbb{N}$ tel que $n \geq 2$. L'espace vectoriel $\mathbb{R}^n$ est muni de sa structure euclidienne canonique, le produit scalaire étant noté $\langle ., . \rangle$ et la norme associée $\|.\|$. Soit f une application de classe C^1 définie sur $\mathbb{R}^n$, à valeurs dans $\mathbb{R}$, convexe, c'est-à-dire vérifiant pour tout $(x, y) \in (\mathbb{R}^n)^2$ et pour tout réel $\lambda \in [0, 1]$:

$$f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y).$$

Pour tout $(h, x) \in (\mathbb{R}^n)^2$ fixé, on définit la fonction $\varphi_{h,x}$ de la variable réelle t par :

$$\varphi_{h,x}(t) = f(x + th).$$

1. a. Montrer que $\varphi_{h,x}$ est une fonction convexe de $\mathbb{R}$ dans $\mathbb{R}$.
   b. En déduire que $\varphi_{(h,x)'}(0) \leq \varphi_{h,x}(1) - \varphi_{h,x}(0)$.
2. Montrer que pour tout $(x, y) \in (\mathbb{R}^n)^2$, on a

   $$\langle \nabla f(x), y - x \rangle \leq f(y) - f(x).$$

   En déduire que si x est un point critique de f, alors f possède un minimum, atteint en x.
3. On suppose dans cette question que $f(0) = 0$ et que $\nabla f(0) = 0$. On suppose également que f est strictement convexe, c'est-à-dire qu'elle vérifie pour tout $(x, y) \in (\mathbb{R}^n)^2$, tels que $x \neq y$, pour tout réel $\lambda \in]0, 1[$:

   $$f((1-\lambda)x + \lambda y) < (1-\lambda)f(x) + \lambda f(y).$$

   a. Montrer que pour tout $x \in \mathbb{R}^n$, $f(0) \leq f(x)$, puis que si $x \neq 0$, alors $f(x) \neq 0$.
   b. Montrer que $\inf_{x\in\mathbb{R}^n, \|x\|=1} f(x)$ existe. On note α cette valeur. Montrer que $\alpha > 0$.
   c. Montrer que pour tout $\|x\| > 1$, $|f(x)| \geq \alpha\|x\|$. En déduire la valeur de $\lim_{\|x\|\to+\infty} f(x)$.

Correction :

1. a. Il s'agit de revenir à la définition : soient $t_1, t_2 \in \mathbb{R}$ et $\lambda \in [0, 1]$. Alors

$$\begin{aligned}\varphi_{h,x}(\lambda t_1 + (1-\lambda)t_2) &= f(x + (\lambda t_1 + (1-\lambda)t_2)h) \\ &= f(\lambda(x + t_1 h) + (1-\lambda)(x + t_2 h)) \\ &\leq \lambda f(x + t_1 h) + (1-\lambda) f(x + t_2 h) \\ &= \lambda \varphi_{h,x}(t_1) + (1-\lambda)\varphi_{h,x}(t_2).\end{aligned}$$

Donc $\varphi_{h,x}$ est convexe.

b. $\varphi_{h,x}$ étant convexe, ses cordes sont au-dessus de ses tangentes. En particulier, la tangente en 0 est la droite d'équation $y = \varphi_{(h,x)'}(0)t + \varphi_{h,x}(0)$. Donc pour $t = 1$, on a $\varphi_{h,x}(1) \geq \varphi_{(h,x)'}(0) + \varphi_{h,x}(0)$ soit encore

$$\varphi_{(h,x)'}(0) \leq \varphi_{h,x}(1) - \varphi_{h,x}(0).$$

2. On sait que $\varphi_{(h,x)'}(0) = \langle \nabla f(x), h\rangle$. En particulier, si on prend $h = y - x$, alors il vient

$$\langle \nabla f(x), y - x\rangle \leq \varphi_{y-x,x}(1) - \varphi_{y-x,x}(0) = f(y) - f(x).$$

En particulier, si x est un point critique de f, $\nabla f(x) = 0$ et donc pour tout $y \in \mathbb{R}^n$,

$$0 \leq f(y) - f(x) \Leftrightarrow f(x) \leq f(y).$$

f possède alors un minimum en x.

3. a. Pour $x = 0$, la relation précédente donne pour tout $y \in \mathbb{R}^n$,

$$0 \leq f(y).$$

S'il existait un $x \neq 0$ tel que $f(x) = 0$, alors il viendrait

$$f\left(\frac{0+x}{2}\right) < \frac{f(0) + f(x)}{2} = 0.$$

Ceci est contradictoire avec $f(y) \geq 0$ pour tout $y \in \mathbb{R}^n$.

b. La sphère unité $S = \{x \in \mathbb{R}^n \mid \|x\| = 1\}$ est fermée et bornée dans $\mathbb{R}^n$. Comme f est continue, la restriction de f à S atteint ses bornes, en particulier son minimum. Ainsi, l'infimum

$$\alpha = \inf_{x \in \mathbb{R}^n, \|x\|=1} f(x)$$

existe.

De plus, pour tout $x \in S$, on a $x \neq 0$, donc d'après la question précédente $f(x) \neq 0$. Or on sait aussi que $f(x) \geq 0$ pour tout $x \in \mathbb{R}^n$. Donc, pour tout $x \in S$, $f(x) > 0$.

Si $\alpha = 0$, comme le minimum est atteint sur S, il existerait $x_0 \in S$ tel que $f(x_0) = 0$, ce qui contredirait ce qui précède. Par conséquent, $\alpha > 0$.

c. Soit $x \in \mathbb{R}^n$ tel que $\|x\| > 1$, et posons $u = \frac{x}{\|x\|}$. Alors $\|u\| = 1$, donc par définition de α, on a $f(u) \geq \alpha$.

De plus,

$$u = \frac{1}{\|x\|}x + \left(1 - \frac{1}{\|x\|}\right)0$$

avec $\frac{1}{\|x\|} \in]0,1[$. Par convexité de f et comme $f(0) = 0$,

$$f(u) \leq \frac{1}{\|x\|} f(x).$$

Ainsi,

$$\alpha \leq f(u) \leq \frac{f(x)}{\|x\|},$$

donc

$$f(x) \geq \alpha \|x\|.$$

Comme $f(x) \geq 0$, on a bien $|f(x)| = f(x) \geq \alpha\|x\|$.

Puisque $\alpha > 0$ et $\alpha\|x\| \underset{\|x\| \to +\infty}{\to} +\infty$, on en déduit par comparaison que

$$\lim_{\|x\| \to +\infty} f(x) = +\infty.$$